

Relatório Técnico: MedAssist RAG

Sistema de Suporte à Decisão Clínica com IA Local

Disciplina: CC0121 - Inteligência Artificial

Data: 15 de Julho de 2026

1. Introdução

O projeto MedAssist RAG surge da necessidade premente de ferramentas digitais seguras e eficientes para profissionais de saúde. Em cenários clínicos de alta demanda, a rapidez e a precisão no acesso a informações cruciais sobre medicamentos são fatores determinantes para a qualidade do atendimento e a segurança do paciente. Este relatório técnico detalha a concepção, arquitetura, implementação e os resultados alcançados por um sistema de Recuperação Aumentada por Geração (RAG) inovador, focado especificamente em bulas médicas. O objetivo principal é fornecer um suporte à decisão terapêutica que seja robusto, confiável e, acima de tudo, garanta a privacidade dos dados sensíveis dos pacientes através de um processamento 100% local.

2. Descrição do Problema

O cenário atual da medicina é caracterizado por um volume crescente de informações e uma complexidade farmacológica em constante evolução. Profissionais de saúde, como médicos e farmacêuticos, são frequentemente confrontados com a necessidade de consultar e interpretar bulas de medicamentos que são, por natureza, extensas, densas em terminologia técnica e, por vezes, de difícil comparação. Os principais desafios identificados que o MedAssist RAG busca resolver incluem:

- Tempo Escasso:** A rotina clínica não permite longos períodos para a leitura integral e comparativa de múltiplas bulas, o que pode levar a decisões subótimas ou atrasos no tratamento.
- Complexidade e Volume de Dados:** O grande volume de informações contido em cada bula, somado à necessidade de considerar interações medicamentosas e contraindicações para diversos fármacos, torna a tarefa de análise manual extremamente onerosa e propensa a erros.
- Risco de Erro Humano:** A fadiga e a sobrecarga de trabalho aumentam a probabilidade de falhas na interpretação ou na identificação de detalhes críticos nas bulas, com potenciais consequências graves para a saúde do paciente.

- **Preocupações com Privacidade de Dados:** A crescente utilização de sistemas de IA baseados em nuvem levanta sérias questões sobre a segurança e a privacidade de dados sensíveis de pacientes, especialmente em conformidade com regulamentações como a LGPD no Brasil. A transmissão de informações clínicas para servidores externos é um risco inaceitável para muitas instituições de saúde.

3. Metodologia e Arquitetura do Sistema RAG

A solução MedAssist RAG foi projetada com uma arquitetura RAG (Retrieval-Augmented Generation) que opera de forma totalmente local, garantindo a soberania dos dados e a privacidade. O pipeline de processamento pode ser dividido nas seguintes etapas:

3.1. Ingestão de Dados

Esta fase envolve a preparação do corpus de conhecimento que servirá de base para as respostas do sistema. As bulas médicas são fornecidas em formato Markdown (`.md`), o que facilita a padronização e a extração de texto. Os documentos são carregados utilizando o `DirectoryLoader` e `TextLoader` da biblioteca LangChain. Após o carregamento, os documentos são segmentados em chunks menores utilizando o `RecursiveCharacterTextSplitter`. Cada chunk possui um tamanho de 1200 caracteres com uma sobreposição de 200 caracteres, o que ajuda a manter o contexto entre os segmentos e melhora a qualidade da recuperação.

3.2. Vetorização

Após a segmentação, cada chunk de texto é transformado em uma representação numérica (vetor) que captura seu significado semântico. Para isso, é utilizado o modelo de embeddings `omic-embed-text`, executado localmente via Ollama. A vetorização é um passo crucial, pois permite que o sistema compare a similaridade semântica entre a consulta do usuário e os trechos das bulas, em vez de depender apenas de correspondência exata de palavras-chave.

3.3. Armazenamento e Recuperação

Os vetores gerados são armazenados em um banco de dados vetorial, o ChromaDB. Este banco de dados é persistente e também opera localmente, reforçando o compromisso com a privacidade. Quando uma consulta é feita, o sistema realiza uma busca semântica no ChromaDB para identificar os chunks de bulas mais relevantes. Para otimizar a recuperação e evitar a redundância de informações, é empregado o algoritmo MMR (Maximal Marginal Relevance), que seleciona documentos que são tanto relevantes para a consulta quanto diversos entre si. Isso garante que o contexto fornecido ao LLM seja abrangente e não repetitivo.

3.4. Geração Aumentada

Os trechos de bulas recuperados servem como contexto para um Large Language Model (LLM) que, neste projeto, é o `qwen2.5:7b-instruct`, também executado localmente via Ollama. O LLM recebe a consulta do usuário e o contexto relevante das bulas, e é instruído a gerar uma resposta que sintetize as informações de forma clara, objetiva e estruturada. O prompt de sistema é cuidadosamente elaborado para garantir que o LLM siga um formato de saída específico, incluindo marcadores para NOME, ALINHAMENTO, PRÓS e CONTRAS de cada medicamento, e que se restrinja estritamente às informações contidas no contexto fornecido, minimizando o risco de alucinações.

4. Tecnologias Utilizadas

A implementação do MedAssist RAG se baseia em um conjunto de tecnologias de código aberto, escolhidas por sua robustez, flexibilidade e capacidade de operar em ambientes locais:

Categoria	Tecnologia	Descrição
Linguagem	Python 3.11+	Linguagem de programação principal para o desenvolvimento do sistema.
Framework RAG	LangChain	Orquestração do pipeline de RAG, desde a ingestão até a geração.
Interface	Streamlit	Criação de uma interface web interativa e amigável para o usuário final.
LLM Local	Ollama	Plataforma para execução de Large Language Models e modelos de embedding localmente.
Embeddings	<code>nomic-embed-text</code>	Modelo de embedding para transformar texto em vetores numéricos.
LLM de Geração	<code>qwen2.5:7b-instruct</code>	Modelo de linguagem para a geração de respostas contextuais.
Banco Vetorial	ChromaDB	Armazenamento e recuperação eficiente de vetores de documentos.

5. Implementação e Detalhes Técnicos

5.1. Configuração do Ambiente

Para garantir a portabilidade e facilidade de uso, o projeto é configurado para ser executado em um ambiente local. As dependências são gerenciadas via `requirements.txt`, e a instalação do Ollama é um pré-requisito fundamental para o funcionamento dos modelos de linguagem e embeddings. Os modelos `nomic-embed-text` e `qwen2.5:7b-instruct` são baixados e executados através do Ollama, garantindo que todo o processamento de IA ocorra na máquina local do usuário.

5.2. Interface do Usuário (Streamlit)

A interface do MedAssist RAG é desenvolvida com Streamlit, oferecendo uma experiência de usuário intuitiva e responsiva. A aplicação permite que o profissional de saúde insira o quadro clínico do paciente em linguagem natural. A interface também inclui funcionalidades como:

- **Alternância de Tema:** Modos claro e escuro para melhor adaptação a diferentes condições de iluminação em ambientes clínicos.
- **Gerenciamento de Bulas:** Ferramentas para adicionar e remover bulas do acervo, bem como para reconstruir o banco vetorial, garantindo que o sistema esteja sempre atualizado com as informações mais recentes.
- **Visualização de Fontes:** Cada resposta gerada pela IA é acompanhada pelos trechos exatos das bulas que foram utilizados como base, permitindo que o profissional valide a informação e compreenda o raciocínio do sistema.

5.3. Pipeline RAG no Código

O coração do sistema é o pipeline RAG, implementado com LangChain. A `rag_chain` é construída de forma modular:

1. **Retriever:** O `retriever` é configurado para buscar os 5 chunks mais relevantes (`k=5`) de um universo de 15 chunks (`fetch_k=15`), utilizando a busca MMR para diversidade.
2. **Prompt Template:** Um `ChatPromptTemplate` rigoroso é definido para guiar o LLM na formatação da saída, assegurando que as informações sobre NOME, ALINHAMENTO, PRÓS e CONTRAS sejam apresentadas de maneira padronizada.
3. **LLM:** O `ChatOllama` é instanciado com o modelo `qwen2.5:7b-instruct` e uma temperatura de 0, para garantir respostas determinísticas e factuais.
4. **Output Parser:** Um `StrOutputParser` é utilizado para extrair a resposta textual do LLM.

6. Resultados Obtidos e Validação

O MedAssist RAG foi submetido a testes rigorosos para avaliar sua eficácia e confiabilidade. Os principais resultados e observações incluem:

- **Acurácia de Recuperação:** A combinação de embeddings de alta qualidade (`nomic-embed-text`) e o algoritmo MMR no ChromaDB resultou em uma recuperação de informações altamente precisa e relevante, mesmo para consultas complexas ou ambíguas. Isso é fundamental para garantir que o LLM receba o contexto correto para gerar suas respostas.
- **Zero Alucinação:** Um dos maiores desafios em sistemas baseados em LLMs é a tendência à alucinação (gerar informações falsas ou não suportadas pelos dados de origem). Graças à arquitetura RAG e ao prompt de sistema cuidadosamente elaborado, o MedAssist RAG demonstrou uma capacidade excepcional de se ater estritamente às informações contidas nas bulas. Em nenhum dos testes realizados, o sistema inventou dados ou apresentou informações incorretas que não pudessem ser verificadas nas fontes originais.
- **Eficiência na Triagem:** O sistema reduziu drasticamente o tempo necessário para analisar e comparar informações de medicamentos. O que antes levava minutos ou até horas de consulta manual, agora é processado em segundos, permitindo que os profissionais de saúde dediquem mais tempo ao cuidado direto do paciente.
- **Conformidade e Segurança:** Ao operar 100% localmente, o MedAssist RAG elimina as preocupações com a transmissão de dados sensíveis para serviços de nuvem de terceiros, garantindo total conformidade com as regulamentações de privacidade de dados, como a LGPD.

7. Conclusão

O MedAssist RAG representa um avanço significativo no suporte à decisão clínica, demonstrando como a inteligência artificial pode ser aplicada de forma ética e segura em um dos setores mais críticos da sociedade. A implementação de um sistema RAG totalmente local, combinado com uma interface intuitiva e a capacidade de fornecer fontes verificáveis, oferece aos profissionais de saúde uma ferramenta poderosa para otimizar a triagem clínica, aumentar a segurança do paciente e garantir a privacidade dos dados. O projeto não apenas cumpre seus objetivos técnicos, mas também estabelece um novo padrão para a aplicação responsável da IA na medicina.

8. Referências

[1] LangChain. (s.d.). *LangChain Documentation*. Disponível em: <https://www.langchain.com/> [2] Ollama. (s.d.). *Run Llama 2, Mistral, and other large language models locally*. Disponível em: <https://ollama.com/> [3] Streamlit. (s.d.). *The fastest way to build and share data apps*. Disponível

em: <https://streamlit.io/> [4] Chroma. (s.d.). *The AI-native open-source embedding database*.
Disponível em: <https://www.trychroma.com/>
